

ESTADÍSTICA MULTIVARIANTE

UGR, GRADO EN MATEMÁTICAS
Curso Académico 2023-2024

José Miguel Angulo Ibáñez (*jmangulo@ugr.es*)

Departamento de Estadística e Investigación Operativa
Universidad de Granada

► **TEMA 1. Distribución Normal Multivariante**

Caso $\Sigma > 0$: definiciones, propiedades y caracterizaciones

Definición en términos de la densidad

- DEFINICIÓN: Sea $\mathbf{X} = (X_1, \dots, X_p)'$ un vector aleatorio. Se dice que \mathbf{X} tiene una *distribución normal p -variante* si su densidad es de la forma

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{p}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}, \quad \forall \mathbf{x} \in \mathbb{R}^p,$$

siendo $\boldsymbol{\mu} = (\mu_1, \dots, \mu_p)' \in \mathbb{R}^p$ y Σ una matrix escalar $(p \times p)$ -dimensional simétrica y definida positiva

Se denota $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$, representando $\boldsymbol{\mu}$ y Σ los ‘parámetros’ de la distribución

Se demuestra que $f_{\mathbf{X}}$ está bien definida, es decir, que cumple las condiciones para ser una función de densidad:

1. $f_{\mathbf{X}}(\mathbf{x}) \geq 0, \forall \mathbf{x} \in \mathbb{R}^p$

(□ Probar)

2. $\int_{\mathbb{R}^p} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = 1$

(□ Probar)

Vector de medias y matriz de covarianzas

- A partir de cualquier factorización de la forma

$$\Sigma = CC',$$

para alguna matriz C de dimensión $p \times p$ no singular (por ser $\Sigma > 0$), se tiene que el vec.a. $\mathbf{Z} = (Z_1, \dots, Z_p)'$ definido por

$$\mathbf{Z} = C^{-1}(\mathbf{X} - \boldsymbol{\mu}) \quad (\text{es decir, con } \mathbf{X} = C(\mathbf{Z} + \boldsymbol{\mu}))$$

se distribuye con función de densidad

$$f_{\mathbf{Z}}(\mathbf{z}) = \prod_{j=1}^p \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{1}{2} z_j^2 \right\} = \prod_{j=1}^p f_{Z_j}(z_j)$$

Es decir, para cada $j = 1, \dots, p$,

$$Z_j \sim N_1(0, 1),$$

siendo Z_1, \dots, Z_p independientes (por tanto, incorreladas), y

$$\mathbf{Z} \sim N_p(\mathbf{0}, I_p)$$

- Se comprueba de forma inmediata que μ y Σ representan, respectivamente, el vector de medias y la matriz de covarianzas del vector aleatorio \mathbf{X} , es decir:

$$\mu_{\mathbf{X}} = \mu$$

$$\Sigma_{\mathbf{X}} = \Sigma$$

(□ Probar)

[1] CAMBIO DE VARIABLES LINEAL:

Sean

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}_X, \Sigma_X) \quad (\Sigma > 0)$$

$$\mathbf{Y} = B\mathbf{X} + \mathbf{b} \quad \text{con}$$

B matriz $p \times p$ (cte.) no singular

\mathbf{b} vector $p \times 1$ (cte.)

Entonces, se tiene que

$$\mathbf{Y} \sim N_p(\boldsymbol{\mu}_Y, \Sigma_Y) = N_p(B\boldsymbol{\mu}_X + \mathbf{b}, B\Sigma_X B') \quad (\square \text{ Probar})$$

● CARACTERIZACIÓN I:

Un vector aleatorio p -dimensional \mathbf{X} tiene una DNM no singular, $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ ($\Sigma > 0$), si y solo si

$$\mathbf{X} \stackrel{d}{=} A\mathbf{Z} + \boldsymbol{\mu} \quad \text{con}$$

A matriz $p \times p$ (cte.) no singular, $AA' = \Sigma$

$$\mathbf{Z} \sim N_p(\mathbf{0}, I_p)$$

(\square Probar)

[2] INDEPENDENCIA Y CONDICIONAMIENTO:

Vemos a continuación algunos resultados fundamentales (dos sobre independencia y uno sobre condicionamiento) que, entre otras posibilidades, pueden tratarse a partir de la definición de la DNM no singular en términos de su densidad

- RESULTADO 1: Sea $\mathbf{X} = (X_1, \dots, X_p)'$ un vector aleatorio con DNM no singular,

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma) \quad (\Sigma > 0).$$

Si la matriz Σ es diagonal,

$$\Sigma = \begin{pmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_p^2 \end{pmatrix} = \text{diag}(\sigma_1^2, \dots, \sigma_p^2),$$

entonces las variables aleatorias componentes del vector, X_i , $i = 1, \dots, p$, son independientes y tienen DN univariante (no degenerada),

$$X_i \sim N(\mu_i, \sigma_i^2) \quad (\sigma_i^2 > 0), \quad i = 1, \dots, p \quad (\square \text{ Probar})$$

- El recíproco de este resultado es cierto en el siguiente sentido:

Si $\mathbf{X} = (X_1, \dots, X_p)'$ es un vector aleatorio con componentes (mutuamente) independientes, cada una de ellas con DN univariante (no degenerada),

$$X_i \sim N(\mu_i, \sigma_i^2) \quad (\sigma_i^2 > 0), \quad i = 1, \dots, p,$$

entonces \mathbf{X} tiene DNM no singular,

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma), \quad \text{con} \quad \Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_p^2) \quad (\Sigma > 0)$$

(OBSERVACIÓN: El resultado no es válido si solo se supone la incorrelación, o incluso la ‘independencia dos a dos’, entre las componentes del vector)

- El Resultado 1 se puede generalizar al caso en que la matriz Σ es una matriz diagonal por cajas, estableciéndose las conclusiones en términos de los correspondientes subvectores del vector \mathbf{X} (se enunciará, por simplicidad, en el caso de dos subvectores):

Algunas propiedades (caso $\Sigma > 0$) (cont.)

- RESULTADO 2: Sea $\mathbf{X} = (X_1, \dots, X_p)'$ un vector aleatorio con DNM no singular,

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma) \quad (\Sigma > 0)$$

Supongamos que las componentes de \mathbf{X} están ordenadas de tal modo que para la partición del vector

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_{(1)} \\ \mathbf{X}_{(2)} \end{pmatrix}, \quad \text{con } \mathbf{X}_{(1)} = (X_1, \dots, X_q)', \mathbf{X}_{(2)} = (X_{q+1}, \dots, X_p)',$$

se tiene

$$\boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_{(1)} \\ \boldsymbol{\mu}_{(2)} \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{(11)} & \Sigma_{(12)} \\ \Sigma_{(21)} & \Sigma_{(22)} \end{pmatrix} = \begin{pmatrix} \Sigma_{(11)} & 0 \\ 0 & \Sigma_{(22)} \end{pmatrix}$$

(i. e., $\Sigma = \text{diag}(\Sigma_{(11)}, \Sigma_{(22)})$). Entonces, los vectores aleatorios $\mathbf{X}_{(1)}$ y $\mathbf{X}_{(2)}$ son (mutuamente) independientes y tienen cada uno DNM, de dimensiones respectivas q y $p - q$,

$$\mathbf{X}_{(1)} \sim N_q(\boldsymbol{\mu}_{(1)}, \Sigma_{(11)})$$

$$\mathbf{X}_{(2)} \sim N_{p-q}(\boldsymbol{\mu}_{(2)}, \Sigma_{(22)})$$

(□ Probar)

Algunas propiedades (caso $\Sigma > 0$) (cont.)

- RESULTADO 3: Sea (como en el Resultado 2)

$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ ($\Sigma > 0$), con el particionamiento

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}_{(1)} \\ \mathbf{X}_{(2)} \end{pmatrix}, \quad \boldsymbol{\mu} = \begin{pmatrix} \boldsymbol{\mu}_{(1)} \\ \boldsymbol{\mu}_{(2)} \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{(11)} & \Sigma_{(12)} \\ \Sigma_{(21)} & \Sigma_{(22)} \end{pmatrix}$$

Entonces, se tiene que

- (1) Los vectores $\mathbf{X}_{(1)}$ y $\mathbf{X}_{(2)} - \Sigma_{(21)}\Sigma_{(11)}^{-1}\mathbf{X}_{(1)}$ son independientes
- (2) Dichos vectores se distribuyen según
 - $\mathbf{X}_{(1)} \sim N_q(\boldsymbol{\mu}_{(1)}, \Sigma_{(11)})$
 - $\mathbf{X}_{(2)} - \Sigma_{(21)}\Sigma_{(11)}^{-1}\mathbf{X}_{(1)} \sim N_{p-q}(\boldsymbol{\mu}_{(2)} - \Sigma_{(21)}\Sigma_{(11)}^{-1}\boldsymbol{\mu}_{(1)}, \Sigma_{(22)} - \Sigma_{(21)}\Sigma_{(11)}^{-1}\Sigma_{(12)})$
- (3) La distribución condicionada de $\mathbf{X}_{(2)}$ dado $\mathbf{X}_{(1)} = \mathbf{x}_{(1)}$ es una DNM, de la forma

$$N_{p-q}(\boldsymbol{\mu}_{(2)} + \Sigma_{(21)}\Sigma_{(11)}^{-1}(\mathbf{x}_{(1)} - \boldsymbol{\mu}_{(1)}), \Sigma_{(22)} - \Sigma_{(21)}\Sigma_{(11)}^{-1}\Sigma_{(12)})$$

(□ Probar)

(En adelante, se denotará $\Sigma_{22 \cdot 1} = \Sigma_{(22)} - \Sigma_{(21)}\Sigma_{(11)}^{-1}\Sigma_{(12)}$)

Función característica de la DNM (caso $\Sigma > 0$)

La función característica de la DNM, en el caso no singular ($\Sigma > 0$), puede obtenerse de forma directa a partir de la función de densidad

● CARACTERIZACIÓN II:

Un vector aleatorio p -dimensional \mathbf{X} con vector de medias $\boldsymbol{\mu}$ y matriz de covarianzas $\Sigma > 0$ tiene una DNM no singular, $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$, si y solo si su función característica tiene la forma

$$\phi_{\mathbf{X}}(\mathbf{t}) = \exp \left\{ i\mathbf{t}'\boldsymbol{\mu} - \frac{1}{2}\mathbf{t}'\Sigma\mathbf{t} \right\} \quad (\square \text{ Probar})$$

(OBSERVACIÓN: Se verá más adelante que en el caso singular, con Σ semidefinida positiva, la función característica tiene la misma expresión formal)

- Frente al uso directo de la función de densidad (caso no singular), la función característica es muy útil en la derivación de diversos resultados, algunos de los cuales se ven a continuación

- RESULTADO 4:

Sean

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}_X, \Sigma_X) \quad (\Sigma_X > 0)$$

$$\mathbf{Y} = B\mathbf{X} + \mathbf{b} \quad \text{con}$$

B matriz $q \times p$ (cte.) de rango q ($\Rightarrow q \leq p$)

\mathbf{b} vector $q \times 1$ (cte.)

Entonces, se tiene que

$$\mathbf{Y} \sim N_q(\boldsymbol{\mu}_Y, \Sigma_Y) = N_q(B\boldsymbol{\mu}_X + \mathbf{b}, B\Sigma_X B'),$$

(siendo $\text{rango}(B\Sigma_X B') = q$, es decir, $B\Sigma_X B' > 0$) (□ Probar)

Marginalización (caso $\Sigma > 0$)

- En particular, del resultado anterior se obtiene el siguiente, sobre normalidad de las distribuciones marginales en una DNM

RESULTADO 5:

Sea

$$\mathbf{X} = (X_1, \dots, X_p)' \sim N_p(\boldsymbol{\mu}, \Sigma) \quad (\Sigma > 0)$$

Entonces, para todo subvector

$$\mathbf{X}_{\mathbf{r}} = (X_{r_1}, \dots, X_{r_q})', \quad \mathbf{r} = (r_1, \dots, r_q)', \quad q \leq p,$$

(con r_1, \dots, r_q distintos entre sí) se tiene que

$$\mathbf{X}_{\mathbf{r}} \sim N_q(\boldsymbol{\mu}_{\mathbf{r}}, \Sigma_{\mathbf{r}}) \quad (\Sigma_{\mathbf{r}} > 0)$$

siendo

$\boldsymbol{\mu}_{\mathbf{r}}$ el subvector de $\boldsymbol{\mu}$ correspondiente a \mathbf{r}

$\Sigma_{\mathbf{r}}$ la submatriz principal de Σ correspondiente a \mathbf{r}

(□ Probar)

Caracterización de la DNM en términos de normalidad de combinaciones lineales de las componentes (caso $\Sigma > 0$)

• CARACTERIZACIÓN III:

Un vector aleatorio p -dimensional $\mathbf{X} = (X_1, \dots, X_p)'$ tiene una DNM no singular si y solo si toda combinación de la forma

$$\alpha' \mathbf{X}, \quad \text{con } \alpha \in \mathbb{R}^p - \{\mathbf{0}\},$$

tiene una DN univariante no degenerada (*i. e.*, con varianza no nula)

(□ Probar)

Caracterización de la DNM en términos de la densidad esférica estándar (caso $\Sigma > 0$)

- Sea $\mathbf{X} = (X_1, \dots, X_p)'$ un vector aleatorio con DNM no singular,

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma) \quad (\Sigma > 0)$$

Para alguna elección de una matriz C no singular con $\Sigma = CC'$, consideramos la normalización de \mathbf{X} dada por el vector aleatorio

$$\mathbf{Z} := C^{-1}(\mathbf{X} - \boldsymbol{\mu}) \sim N_p(\mathbf{0}, I_p)$$

Definimos ahora el vector aleatorio

$$\mathbf{U} := \frac{\mathbf{Z}}{\|\mathbf{Z}\|} = \frac{\mathbf{Z}}{(\mathbf{Z}'\mathbf{Z})^{\frac{1}{2}}}$$

Puesto que $\|\mathbf{U}\| = \left\| \frac{\mathbf{Z}}{\|\mathbf{Z}\|} \right\| = \frac{\|\mathbf{Z}\|}{\|\mathbf{Z}\|} = 1$, se tiene que \mathbf{U} se distribuye sobre la esfera unidad en \mathbb{R}^p , \mathcal{S}_p . Además, se cumple que

$$\mathbf{U} \stackrel{d}{=} H\mathbf{U}$$

para toda matriz ortogonal H de dimensión p (i. e., $HH' = H'H = I_p$); es decir, \mathbf{U} ha de tener la distribución uniforme sobre \mathcal{S}_p (*distribución esférica sobre la esfera unidad*) (□ Probar)

Caracterización de la DNM en términos de la densidad esférica estándar (caso $\Sigma > 0$) (cont.)

- Un RESULTADO importante:

El vector aleatorio

$$\mathbf{U} = \frac{\mathbf{Z}}{(\mathbf{Z}'\mathbf{Z})^{\frac{1}{2}}}$$

y la variable aleatoria

$$R = (\mathbf{Z}'\mathbf{Z})^{\frac{1}{2}}$$

son independientes

(Este resultado se demuestra, en general, para vectores aleatorios con distribución esférica)

Caracterización de la DNM en términos de la densidad esférica estándar (caso $\Sigma > 0$) (cont.)

● CARACTERIZACIÓN IV:

Un vector aleatorio p -dimensional $\mathbf{X} = (X_1, \dots, X_p)'$ tiene una DNM no singular,

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma) \quad (\Sigma > 0),$$

si y solo si las realizaciones de \mathbf{X} pueden generarse a partir del siguiente procedimiento (experimento aleatorio):

1. Observar el valor de una variable aleatoria $R^2 := V \sim \chi_p^2$

→ Se identifica $V = v$

2. Elegir aleatoriamente (*i. e.*, según la distribución uniforme), y de forma independiente, un punto en la esfera p -dimensional de radio $r = \sqrt{v}$

→ Se identifica como $\mathbf{Z} = (Z_1, \dots, Z_p)' = (z_1, \dots, z_p)' = \mathbf{z}$

3. Dados un vector de medias $\boldsymbol{\mu}$ y una matriz de covarianzas $\Sigma > 0$, eligiendo C no singular tal que $\Sigma = CC'$, obtener el valor de \mathbf{X} mediante la expresión $\mathbf{X} := C\mathbf{Z} + \boldsymbol{\mu}$

→ Se identifica $\mathbf{X} = \mathbf{x} = C\mathbf{z} + \boldsymbol{\mu}$