

# ESTADÍSTICA MULTIVARIANTE

**UGR, GRADO EN MATEMÁTICAS**  
**Curso Académico 2023-2024**

---

**José Miguel Angulo Ibáñez** (*jmangulo@ugr.es*)

Departamento de Estadística e Investigación Operativa  
Universidad de Granada

- ▶ **TEMA 2. Inferencia en la Distribución Normal Multivariante**  
Introducción: media muestral y matriz de covarianzas muestral

# ‘Muestra aleatoria simple’ vectorial

- Sea  $\mathbf{X} = (X_1, \dots, X_p)'$  un vector aleatorio con DNM no singular,

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma) \quad (\Sigma > 0)$$

(Por ejemplo, consideremos que las variables representan, en una situación práctica,  $p$  magnitudes relativas a ‘características’ de los ‘individuos’ de una ‘población’, con esa distribución de probabilidad conjunta)

- Se trata de realizar la inferencia (bajo distintas formas) sobre la distribución, supuestos desconocidos total o parcialmente sus parámetros, a partir de una *muestra aleatoria simple* obtenida de ésta (*i. e.*, un conjunto de ‘observaciones’ dadas en términos de *variables aleatorias independientes e idénticamente distribuidas*, con igual distribución que  $\mathbf{X}$ ), que denotaremos

$$\{\mathbf{X}_\alpha : \alpha = 1, \dots, N\} \quad (N = \text{‘tamaño muestral’}),$$

siendo  $X_{\alpha i}$  la componente  $i$ -ésima (correspondiente a la variable  $X_i$ ) de la observación (vectorial)  $\alpha$ -ésima,  $\mathbf{X}_\alpha$

## 'Muestra aleatoria simple' vectorial (cont.)

- Se utilizará la misma notación pero en minúsculas cuando las variables de una muestra aleatoria simple tomen valores numéricos concretos, es decir, se tenga una realización de ésta:

$$\{\mathbf{x}_\alpha : \alpha = 1, \dots, N\} \quad (N = \text{'tamaño muestral'}),$$

- A efectos algebraicos y computacionales, es frecuente disponer las variables componentes de la muestra en forma de 'matriz de datos' (aleatoria),

$$\mathbf{X} = \begin{pmatrix} \mathbf{X}'_1 \\ \vdots \\ \mathbf{X}'_\alpha \\ \vdots \\ \mathbf{X}'_p \end{pmatrix} = \begin{pmatrix} X_{11} & \cdots & X_{1i} & \cdots & X_{1p} \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ X_{\alpha 1} & \cdots & X_{\alpha i} & \cdots & X_{\alpha p} \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ X_{N1} & \cdots & X_{Ni} & \cdots & X_{Np} \end{pmatrix}$$

(y análogamente, usando minúsculas, en el caso de las correspondientes realizaciones de la muestra)

# Medidas muestrales de primer y segundo orden

- En primer lugar, como paso previo a otros aspectos de la inferencia, se abordará en el apartado siguiente la *estimación puntual* de los parámetros  $\mu$  y  $\Sigma$ . Se adoptará el criterio basado en la *maximización de la función de verosimilitud*

Como se verá, los *estimadores máximo-verosímiles* de  $\mu$  y  $\Sigma$  se expresarán en términos de medidas descriptivas de la muestra dadas por el *vector de medias muestral* y la *matriz de dispersiones muestral* (respecto del vector de medias muestral)

- VECTOR DE MEDIAS MUESTRAL ( $p \times 1$ )

$$\bar{\mathbf{X}} := \frac{1}{N} \sum_{\alpha=1}^N \mathbf{X}_{\alpha} = \begin{pmatrix} \frac{1}{N} \sum_{\alpha=1}^N X_{\alpha 1} \\ \vdots \\ \frac{1}{N} \sum_{\alpha=1}^N X_{\alpha p} \end{pmatrix} =: \begin{pmatrix} \bar{X}_1 \\ \vdots \\ \bar{X}_p \end{pmatrix}$$

(cada componente  $\bar{X}_i = \frac{1}{N} \sum_{\alpha=1}^N X_{\alpha i}$  representa la media muestral para la variable correspondiente  $X_i$ ,  $i = 1, \dots, p$ )

$\bar{\mathbf{X}}$  puede verse como el 'centroide' (aleatorio) de la muestra en  $\mathbb{R}^p$

- MATRIZ DE DISPERSIONES MUESTRAL ( $p \times p$ )

$$A := \sum_{\alpha=1}^N (\mathbf{X}_{\alpha} - \bar{\mathbf{X}})(\mathbf{X}_{\alpha} - \bar{\mathbf{X}})'$$
$$= \begin{pmatrix} \sum_{\alpha=1}^N (x_{\alpha 1} - \bar{x}_1)^2 & \sum_{\alpha=1}^N (x_{\alpha 1} - \bar{x}_1)(x_{\alpha 2} - \bar{x}_2) & \dots & \sum_{\alpha=1}^N (x_{\alpha 1} - \bar{x}_1)(x_{\alpha p} - \bar{x}_p) \\ \sum_{\alpha=1}^N (x_{\alpha 2} - \bar{x}_2)(x_{\alpha 1} - \bar{x}_1) & \sum_{\alpha=1}^N (x_{\alpha 2} - \bar{x}_2)^2 & \dots & \sum_{\alpha=1}^N (x_{\alpha 2} - \bar{x}_2)(x_{\alpha p} - \bar{x}_p) \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{\alpha=1}^N (x_{\alpha p} - \bar{x}_p)(x_{\alpha 1} - \bar{x}_1) & \sum_{\alpha=1}^N (x_{\alpha p} - \bar{x}_p)(x_{\alpha 2} - \bar{x}_2) & \dots & \sum_{\alpha=1}^N (x_{\alpha p} - \bar{x}_p)^2 \end{pmatrix}$$

A partir de la matriz de dispersiones muestral, se definen:

- ▶ MATRIZ DE COVARIANZAS MUESTRAL:  $S_N = \frac{A}{N} = (s_{ij})_{i,j=1,\dots,p}$
- ▶ MATRIZ DE CUASI-COVARIANZAS MUESTRAL:  $S_{N-1} = \frac{A}{N-1}$
- ▶ MATRIZ DE CORRELACIONES MUESTRAL:  $R = \left( \frac{s_{ij}}{s_{ii}^{\frac{1}{2}} s_{jj}^{\frac{1}{2}}} \right)_{i,j=1,\dots,p}$   
(puede escribirse como  $R = D^{-\frac{1}{2}} S_N D^{-\frac{1}{2}}$  con  $D = \text{diag}(s_{11}, \dots, s_{pp})$ )

# Fórmula de momentos multivariante muestral

- LEMA: Sea  $\{\mathbf{X}_\alpha : \alpha = 1, \dots, N\}$  una muestra aleatoria de una distribución  $p$ -dimensional, y sea  $\bar{\mathbf{X}}$  el vector de medias muestral. Entonces, para cualquier vector  $\mathbf{b} \in \mathbb{R}^p$ , se verifica que

$$\begin{aligned}\sum_{\alpha=1}^N (\mathbf{X}_\alpha - \mathbf{b}) (\mathbf{X}_\alpha - \mathbf{b})' &= \sum_{\alpha=1}^N (\mathbf{X}_\alpha - \bar{\mathbf{X}}) (\mathbf{X}_\alpha - \bar{\mathbf{X}})' + N(\bar{\mathbf{X}} - \mathbf{b})(\bar{\mathbf{X}} - \mathbf{b})' \\ &= A + N(\bar{\mathbf{X}} - \mathbf{b})(\bar{\mathbf{X}} - \mathbf{b})'\end{aligned}$$

(□ Probar)

En particular, se tiene:

- Con  $\mathbf{b} = \boldsymbol{\mu}$  (vector de medias poblacional, si existe)

$$\sum_{\alpha=1}^N (\mathbf{X}_\alpha - \boldsymbol{\mu}) (\mathbf{X}_\alpha - \boldsymbol{\mu})' = A + N(\bar{\mathbf{X}} - \boldsymbol{\mu})(\bar{\mathbf{X}} - \boldsymbol{\mu})'$$

- Con  $\mathbf{b} = \mathbf{0}$

$$\sum_{\alpha=1}^N \mathbf{X}_\alpha \mathbf{X}_\alpha' = A + N\bar{\mathbf{X}}\bar{\mathbf{X}}'$$

(‘fórmula de momentos multivariante muestral’)