

ESTADÍSTICA MULTIVARIANTE

UGR, GRADO EN MATEMÁTICAS
Curso Académico 2023-2024

José Miguel Angulo Ibáñez (*jmangulo@ugr.es*)

Departamento de Estadística e Investigación Operativa
Universidad de Granada

► **TEMA 2. Inferencia en la Distribución Normal Multivariante**

Estimadores de máxima verosimilitud de μ y Σ en una DNM (I):
Obtención. Teorema de Dykstra. Teorema de Fisher multivariante

- Sea $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ ($\Sigma > 0$), y sea $\{\mathbf{X}_\alpha : \alpha = 1, \dots, N\}$ una muestra aleatoria simple de dicha distribución.

Para una realización dada de la muestra, $\{\mathbf{x}_\alpha : \alpha = 1, \dots, N\}$, la *función de verosimilitud* se expresa como la función (de argumentos $\boldsymbol{\mu}$ y Σ)

$$\begin{aligned} L(\boldsymbol{\mu}, \Sigma; \mathbf{x}_1, \dots, \mathbf{x}_N) &:= f_{\boldsymbol{\mu}, \Sigma}(\mathbf{x}_1, \dots, \mathbf{x}_N) = \prod_{\alpha=1}^N f_{\boldsymbol{\mu}, \Sigma}(\mathbf{x}_\alpha) \\ &= \prod_{\alpha=1}^N \frac{1}{(2\pi)^{\frac{p}{2}} |\Sigma|^{\frac{1}{2}}} \exp \left\{ -\frac{1}{2} (\mathbf{x}_\alpha - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x}_\alpha - \boldsymbol{\mu}) \right\} \\ &= \frac{1}{(2\pi)^{\frac{pN}{2}} |\Sigma|^{\frac{N}{2}}} \exp \left\{ -\frac{1}{2} \sum_{\alpha=1}^N (\mathbf{x}_\alpha - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x}_\alpha - \boldsymbol{\mu}) \right\} \end{aligned}$$

De forma abreviada, se denotará simplemente $L(\boldsymbol{\mu}, \Sigma)$, sobreentendiéndose implícita la realización muestral de referencia

Función de verosimilitud (cont.)

- Mediante operaciones algebraicas, y usando la fórmula de momentos multivariante generalizada (caso $\mathbf{b} = \boldsymbol{\mu}$), se comprueba que la función de verosimilitud puede expresarse de la forma

$$L(\boldsymbol{\mu}, \Sigma) = \frac{1}{(2\pi)^{\frac{pN}{2}} |\Sigma|^{\frac{N}{2}}} \exp \left\{ -\frac{1}{2} \text{tr}(\Sigma^{-1} \tilde{A}) - \frac{N}{2} (\bar{\mathbf{x}} - \boldsymbol{\mu})' \Sigma^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu}) \right\}$$

con $\tilde{A} = \sum_{\alpha=1}^N (\mathbf{x}_{\alpha} - \bar{\mathbf{x}})(\mathbf{x}_{\alpha} - \bar{\mathbf{x}})'$ (es decir, la matriz de dispersiones muestral evaluada en la realización dada de la muestra, $\{\mathbf{x}_{\alpha} : \alpha = 1, \dots, N\}$) (□ Probar)

Más convenientemente, a efectos de maximización, se suele usar la transformación

$$\ln(L(\boldsymbol{\mu}, \Sigma)) = -\frac{pN}{2} \ln(2\pi) - \frac{N}{2} \ln(|\Sigma|) - \frac{1}{2} \text{tr}(\Sigma^{-1} \tilde{A}) - \frac{N}{2} (\bar{\mathbf{x}} - \boldsymbol{\mu})' \Sigma^{-1} (\bar{\mathbf{x}} - \boldsymbol{\mu})$$

(Es habitual proceder, equivalentemente, a la minimización de la función $-\ln(L(\boldsymbol{\mu}, \Sigma))$)

● RESULTADO:

Sea $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \Sigma)$ ($\Sigma > 0$), y sea $\{\mathbf{X}_\alpha : \alpha = 1, \dots, N\}$ una muestra aleatoria simple de dicha distribución. Entonces, los *estimadores máximo-verosímiles* (EMV) de μ y Σ son, respectivamente,

$$\bar{\mathbf{X}} \quad \text{y} \quad \frac{A}{N} = S_N,$$

este último bajo la condición de ser A definida positiva (*)

[(*) Este aspecto se discutirá más adelante, tras la demostración, en relación con el 'Teorema de Dykstra']

- El problema de optimización se podría abordar de forma directa mediante derivación matricial. No obstante, es interesante probar el resultado por el procedimiento que se expodrá a continuación
- Para la demostración, se utilizará el siguiente resultado auxiliar en la parte relativa al estimador del parámetro Σ :

LEMA (Watson): Sea

$$f(G) = -N \ln(|G|) - \text{tr}(G^{-1}D),$$

con argumento G una matriz simétrica definida positiva, y siendo D una matriz simétrica definida positiva dada, ambas $p \times p$. Entonces, existe (y es único) el máximo de f respecto a G , y se alcanza en $G = \frac{1}{N}D$, siendo el valor máximo alcanzado

$$f\left(\frac{1}{N}D\right) = pN \ln(N) - N \ln(|D|) - pN$$

(□ Probar)

- **Demostración:**

- ▶ Maximización de $\ln(L(\mu, \Sigma))$ en μ :

(Se puede hacer, en este caso, independientemente de Σ)

De la forma obtenida para $\ln(L(\mu, \Sigma))$, se desprende que, independientemente del valor de Σ , el máximo se alcanzará donde se minimice la forma cuadrática

$$(\bar{\mathbf{x}} - \mu)' \Sigma^{-1} (\bar{\mathbf{x}} - \mu)$$

Ahora bien, dado que Σ^{-1} es definida positiva (por serlo Σ), la forma cuadrática alcanza el valor mínimo 0 para (y solo para) $\bar{\mathbf{x}} - \mu = 0$, es decir, $\mu = \bar{\mathbf{x}}$. Por tanto, el estadístico definido por

$$\hat{\mu} := \bar{\mathbf{X}} \quad (\text{el vector de medias muestral})$$

es el EMV (único, c.s.) de μ

► Maximización de $\ln(L(\bar{\mathbf{x}}, \Sigma))$ en Σ :

Dado que tratamos de maximizar la función

$$\ln(L(\bar{\mathbf{x}}, \Sigma)) = -\frac{pN}{2}\ln(2\pi) - \frac{N}{2}\ln(|\Sigma|) - \frac{1}{2}\text{tr}(\Sigma^{-1}\tilde{A})$$

(donde ya ha desaparecido el término correspondiente a la forma cuadrática), identificamos, en la notación del 'lema de Watson',

$$G := \Sigma, \quad D := \tilde{A},$$

$$\begin{aligned} f(\Sigma) &:= 2 \left[\ln L(\bar{\mathbf{x}}, \Sigma) + \frac{pN}{2} \ln(2\pi) \right] = pN \ln(2\pi) + 2 \ln(L(\bar{\mathbf{x}}, \Sigma)) \\ &= -N \ln(|\Sigma|) - \text{tr}(\Sigma^{-1}\tilde{A}), \end{aligned}$$

por lo que el máximo de f en Σ (igualmente, entonces, el máximo de $L(\bar{\mathbf{x}}, \Sigma)$ en Σ) se alcanza para (y solo para) $\Sigma = \frac{\tilde{A}}{N} =: \tilde{S}_N$. Por tanto, el estadístico definido por

$$\hat{\Sigma} := \frac{A}{N} = S_N \quad (\text{la matriz de covarianzas muestral})$$

es el EMV (único, c.s.) de Σ



Estimadores máximo-verosímiles de μ y Σ (cont.)

- Se comprueba que el valor máximo alcanzado por la función de verosimilitud en el punto $(\mu, \Sigma) = (\bar{\mathbf{x}}, \tilde{S}_N)$ del espacio paramétrico es

$$L(\mu, \Sigma) = \frac{1}{(2\pi e)^{\frac{pN}{2}} |\tilde{S}_N|^{\frac{N}{2}}} = \left[\frac{N}{(2\pi e) |\tilde{A}|^{\frac{1}{p}}} \right]^{\frac{pN}{2}}$$

(□ Probar)

Como puede verse, este valor máximo no depende directamente del vector de medias muestral, sino del determinante (producto de autovalores) de la matriz dispersiones muestral respecto a éste, de forma inversa

- En relación con el resultado anterior sobre el EMV del par paramétrico (μ, Σ) , se plantea la cuestión siguiente:

Formalmente, puede ocurrir que para una realización concreta de la muestra aleatoria la matriz A resulte ser singular (es decir, semidefinida positiva). Ahora bien, ¿con qué probabilidad puede darse este caso?

- La respuesta viene dada por el ‘teorema de Dykstra’ (1970):

TEOREMA (Dykstra):

Sea $\mathbf{X} \sim N_p(\mu, \Sigma)$ ($\Sigma > 0$). Sea $\{\mathbf{X}_\alpha : \alpha = 1, \dots, N\}$ una muestra aleatoria simple de dicha distribución y sea $A = \sum_{\alpha=1}^N (\mathbf{X}_\alpha - \bar{\mathbf{X}})(\mathbf{X}_\alpha - \bar{\mathbf{X}})'$ la correspondiente matriz de dispersiones muestral. Entonces, A es definida positiva, con probabilidad 1, si y solo si $N > p$.

- Para la demostración del teorema, se establecen algunos resultados previos:

LEMA I:

Sean $\{\mathbf{X}_\alpha : \alpha = 1, \dots, N\}$ vectores [aleatorios o no] de dimensión p . Sea $C = (c_{\alpha\beta})_{\alpha,\beta=1,\dots,N}$ una matriz ortogonal de dimensión $N \times N$. Entonces, definiendo

$$\mathbf{Y}_\alpha = \sum_{\beta=1}^N c_{\alpha\beta} \mathbf{X}_\beta, \quad \alpha = 1, \dots, N,$$

se tiene que

$$\sum_{\alpha=1}^N \mathbf{X}_\alpha \mathbf{X}'_\alpha = \sum_{\alpha=1}^N \mathbf{Y}_\alpha \mathbf{Y}'_\alpha$$

(□ Probar)

LEMA II:

Sean $\{\mathbf{X}_\alpha : \alpha = 1, \dots, N\}$ vectores aleatorios de dimensión p , con $\mathbf{X}_\alpha \sim N_p(\boldsymbol{\mu}_\alpha, \Sigma)$, $\alpha = 1, \dots, N$ (es decir, tienen la misma matriz de covarianzas, aunque posiblemente distinto vector de medias), independientes. Sea $C = (c_{\alpha\beta})_{\alpha,\beta=1,\dots,N}$ una matriz ortogonal de dimensión $N \times N$. Entonces, definiendo

$$\mathbf{Y}_\alpha = \sum_{\beta=1}^N c_{\alpha\beta} \mathbf{X}_\beta, \quad \alpha = 1, \dots, N,$$

se tiene que

- $\mathbf{Y}_\alpha \sim N_p(\boldsymbol{\nu}_\alpha, \Sigma)$, con $\boldsymbol{\nu}_\alpha = \sum_{\beta=1}^N c_{\alpha\beta} \boldsymbol{\mu}_\beta$, $\alpha = 1, \dots, N$
- Los vectores $\{\mathbf{Y}_\alpha : \alpha = 1, \dots, N\}$ son independientes

(□ Probar)

- **Demostración** (esquema):

Consideremos, en nuestro caso, una matriz $B = (b_{\alpha\beta})_{\alpha,\beta=1,\dots,N}$ de dimensión $N \times N$, ortogonal, cuya última fila sea $(\frac{1}{\sqrt{N}}, \dots, \frac{1}{\sqrt{N}})$. Es decir, el resto de filas han de ser vectores ortogonales con éste y entre sí, con norma igual a 1. Definimos el vector

$$\mathbf{Z}_\alpha = \sum_{\beta=1}^N b_{\alpha\beta} \mathbf{X}_\beta, \quad \alpha = 1, \dots, N$$

Por los resultados anteriores (lemas I y II), tenemos que

- $\mathbf{Z}_\alpha \sim N_p(\boldsymbol{\nu}_\alpha, \Sigma)$, con

$$\boldsymbol{\nu}_\alpha = \sum_{\beta=1}^N b_{\alpha\beta} \boldsymbol{\mu} = \left(\sum_{\beta=1}^N b_{\alpha\beta} \right) \boldsymbol{\mu} = \begin{cases} \mathbf{0}, & \text{si } \alpha = 1, \dots, N-1, \\ \frac{N}{\sqrt{N}} \boldsymbol{\mu} = \sqrt{N} \boldsymbol{\mu}, & \text{si } \alpha = N \end{cases}$$

Teorema de Dykstra (cont.)

- Los vectores $\{\mathbf{Z}_\alpha : \alpha = 1, \dots, N\}$ son independientes

- $$\mathbf{Z}_N = \sum_{\beta=1}^N \frac{1}{\sqrt{N}} \mathbf{X}_\beta = \sqrt{N} \left(\frac{1}{N} \sum_{\beta=1}^N \mathbf{X}_\beta \right) = \sqrt{N} \bar{\mathbf{X}}$$

(es decir, $\bar{\mathbf{X}} = \frac{1}{\sqrt{N}} \mathbf{Z}_N$)

- $$A = \sum_{\alpha=1}^N (\mathbf{X}_\alpha - \bar{\mathbf{X}})(\mathbf{X}_\alpha - \bar{\mathbf{X}})' = \sum_{\alpha=1}^N \mathbf{X}_\alpha \mathbf{X}_\alpha' - N \bar{\mathbf{X}} \bar{\mathbf{X}}'$$

$$= \sum_{\alpha=1}^N \mathbf{Z}_\alpha \mathbf{Z}_\alpha' - \mathbf{Z}_N \mathbf{Z}_N' = \sum_{\alpha=1}^{N-1} \mathbf{Z}_\alpha \mathbf{Z}_\alpha'$$

- Como consecuencia, $\bar{\mathbf{X}}$ y A son independientes

Finalmente, observemos que podemos escribir

$$A = Z'Z, \quad \text{con} \quad Z = \begin{pmatrix} \mathbf{Z}'_1 \\ \vdots \\ \mathbf{Z}'_{N-1} \end{pmatrix}, \text{ matriz } (N-1) \times p,$$

$$Z' = (\mathbf{Z}_1 \quad \cdots \quad \mathbf{Z}_{N-1}), \text{ matriz } p \times (N-1)$$

Esto equivale a que la matriz A es definida no negativa.

Por otra parte, se cumple que

$$\text{rango}(Z) = \text{rango}(Z') = \text{rango}(Z'Z) = \text{rango}(A)$$

Por tanto, la demostración quedará concluida probando que

$$\text{rango}(Z) = p, \text{ con probabilidad 1, si y solo si } N > p$$

(□ Probar)



De la demostración del teorema de Dykstra, se tiene también la prueba del siguiente resultado, conocido como ‘teorema de Fisher multivariante’:

TEOREMA (Fisher):

Dada una muestra aleatoria simple $\mathbf{X}_1, \dots, \mathbf{X}_N$ de una distribución $N_p(\boldsymbol{\mu}, \Sigma)$, el vector de medias muestral $\bar{\mathbf{X}}$ se distribuye según una $N_p\left(\boldsymbol{\mu}, \frac{\Sigma}{N}\right)$, y la matriz de dispersiones muestral de igual mo-

do que $\sum_{\alpha=1}^{N-1} \mathbf{Z}_\alpha \mathbf{Z}_\alpha'$, con $\mathbf{Z}_1, \dots, \mathbf{Z}_{N-1}$ vectores aleatorios independientes e idénticamente distribuidos según una $N_p(\mathbf{0}, \Sigma)$, siendo el vector $\bar{\mathbf{X}}$ y la matriz A independientes